GRUPO 5B · INTELIGENCIA COMPUTACIONAL

Qué decir mañana

Guía para los dos integrantes. Presentación de 15 minutos.
Clustering y anomalías en curvas de luz de estrellas periódicas.

Tutor: Christian Díaz. Datos: ALeRCE-ZTF. Léanla los dos esta noche, en voz alta una vez. El guion está escrito para decirlo, no para leerlo pegado a la pantalla.

EN UNA FRASE

Cada estrella periódica es una lista de números (features). Comprimimos esa lista a 8 números con un autoencoder y miramos si ahí aparecen grupos. Sin usar la clase, el agrupamiento casi no recupera las etiquetas: solo las de período largo se apartan. Con la clase (MCDSVDD) mejora, pero Delta Scuti se pierde por completo.

CÓMO REPARTIRSE LOS 15 MINUTOS

Integrante 1, minutos 0 a 7: qué es el proyecto, las cinco clases, los datos, la partición sin filtración y el autoencoder.

Integrante 2, minutos 7 a 15: GMM, cómo leer las métricas, MCDSVDD, por qué falla Delta Scuti, el período como feature importante, y qué falta.

No hagan esto en la presentación

- No corran el notebook en vivo. Reentrena y se demora. Las figuras ya están hechas.
- No abran el código. Muestren cuatro imágenes de la carpeta results.
- Si se traban en una sigla, usen el nombre largo. Está en la última página.

1. El problema, en simple

Una curva de luz es el brillo de una estrella a lo largo del tiempo. En una estrella periódica ese brillo se repite cada cierto tiempo: ese tiempo es el período. ALeRCE mira alertas del telescopio ZTF y ya calculó, para cada objeto, un montón de números que resumen la curva: período, amplitud, color, asimetría, etc. Esos números se llaman features. El modelo no ve la curva dibujada. Ve esa lista de números.

El problema del proyecto es que esa lista es larga (178 números por estrella) y no se puede mirar a ojo. La idea es comprimirla a pocos números, ver si aparecen grupos, y después volver a la curva de luz para entender qué es un objeto típico y qué es un objeto raro.

Las cinco clases

- CEP, Cefeidas. Pulsan. Período de días. Sirven para medir distancias. 1172 objetos.
- DSCT, Delta Scuti. También pulsan, pero el período es de horas. Son las menos: 532.
- EB, binarias eclipsantes. Dos estrellas que se tapan. La curva tiene eclipses. 2689.
- LPV, variables de período largo. Gigantes, período de meses. 1374.
- RRL, RR Lyrae. Pulsan, período de menos de un día. 2652.

Esas cantidades son las que tienen features. En total, 8419 estrellas. EB y RRL, juntas, son más de la mitad del conjunto. DSCT es cinco veces más chica que EB. Ese desbalance importa después.

2. Qué ya estaba hecho y qué hicimos ahora

El notebook Datos_iniciales.ipynb es la etapa 1 del enunciado: explorar. Ahí se vio que muchos datos faltantes no son física de la estrella. Un bloque mide no-detecciones anteriores a la primera alerta: falta cuando ZTF no tiene historial, no cuando la estrella es rara. Otro bloque son colores WISE: falta cuando no hay contraparte en el infrarrojo. Esos dos bloques se descartan. También se vio que los períodos cubren varios órdenes de magnitud, así que hay que pasarlos a logaritmo para que no aplasten al resto.

Las etapas 2 y 3 son los modelos de ahora. La etapa 4, mirar las curvas de los prototipos y de los outliers, todavía no está. Las curvas sí están guardadas.

SI PREGUNTAN POR EL NOTEBOOK INICIAL

Ese notebook explora. El escalado de ahí se calculó con todos los objetos juntos, porque era para mirar. Christian pidió que en los modelos no se haga así. Los modelos nuevos ajustan imputación, recorte y escala solo con entrenamiento, y después los aplican a validación y a test.

3. Cómo están partidos los datos

70% entrenamiento, 15% validación, 15% test. La partición respeta la proporción de cada clase. Ninguna estrella está en dos conjuntos.

- Entrenamiento: 5893 estrellas. Aquí se aprende todo.
- Validación: 1263. Sirve para decidir cuándo parar el entrenamiento.
- Test: 1263. Solo se usa al final, para medir. El modelo no aprende de él.

De 178 features se descartaron 20. Quedaron 158. A los períodos se les aplica log10. A otras columnas positivas (armónicos, parámetros de un proceso gaussiano) se les aplica log1p. Los valores extremos se recortan al percentil 1 y 99. Los huecos se rellenan con la mediana. Después se resta la mediana y se divide por el rango intercuartil, para que todas las features queden en una escala parecida. Esos cuatro cálculos salen solo del entrenamiento.

FRASE LISTA

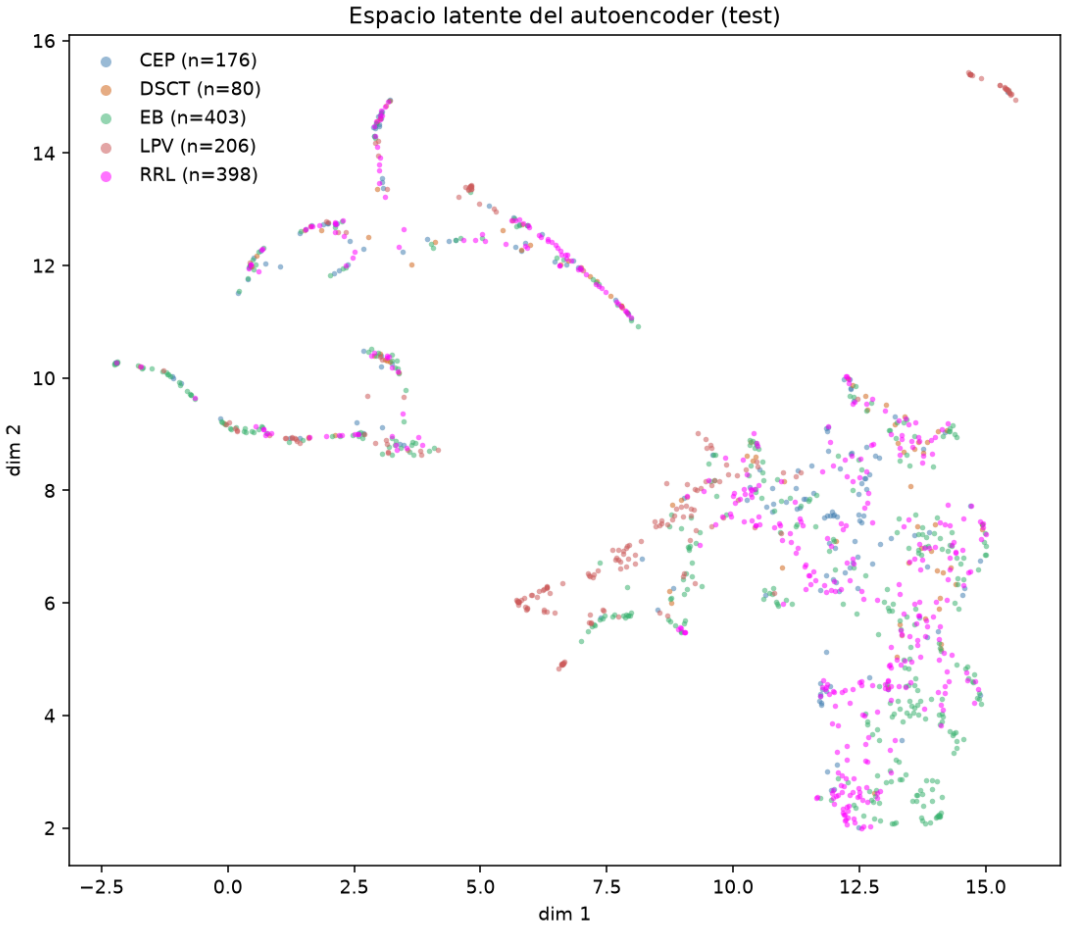
No hay filtración: lo que se ajusta con datos se ajusta solo en entrenamiento. UMAP no entra al modelo. Solo sirve para dibujar el test en dos ejes.

4. Autoencoder

Es una red que comprime y después intenta reconstruir. Entra la lista de 158 números, pasa por capas de 512, 256 y 128, y llega a 8 números. Esos 8 son el cuello de botella, o espacio latente. Desde ahí la red intenta volver a los 158. Si lo logra, esos 8 números guardan lo importante de la estrella.

Entrenó 24 épocas y se detuvo porque la validación dejó de mejorar. El error de reconstrucción en test es 3.19. Ese número está en features ya escaladas: no es una magnitud astronómica y no hace falta defender si es alto o bajo. Lo que se dice es que el entrenamiento paró solo, con validación.

La figura de abajo no es el espacio de 8 dimensiones. Es un mapa de 2 ejes hecho con UMAP, solo para poder mirar el conjunto de test. Cada punto es una estrella. El color es la clase real, que el autoencoder nunca vio.



QUÉ DECIR MIRANDO ESTA FIGURA

Las clases no quedan separadas. LPV, en rojo, se corre un poco hacia un costado, pero Cefeidas, RR Lyrae, binarias y Delta Scuti van mezcladas. El Silhouette usando las clases reales es -0.20. Negativo significa que, en este espacio, la clase no forma un grupo compacto. Por eso el clustering de después, que no usa etiquetas, no puede recuperar las cinco clases.

Por qué 8 dimensiones y no 2: con 2 se aplasta demasiado la información. El enunciado permite un cuello de más de 2 dimensiones y dibujarlo con UMAP. Eso es lo que hicimos.

5. GMM: agrupar sin mirar la clase

Una mezcla de gaussianas pone varias campanas sobre los 8 números. Cada campana es un grupo. Ajustamos 5, una por clase, pero el modelo no sabe cuáles son las clases: solo ve la posición. Se ajusta con el entrenamiento y se evalúa en el test.

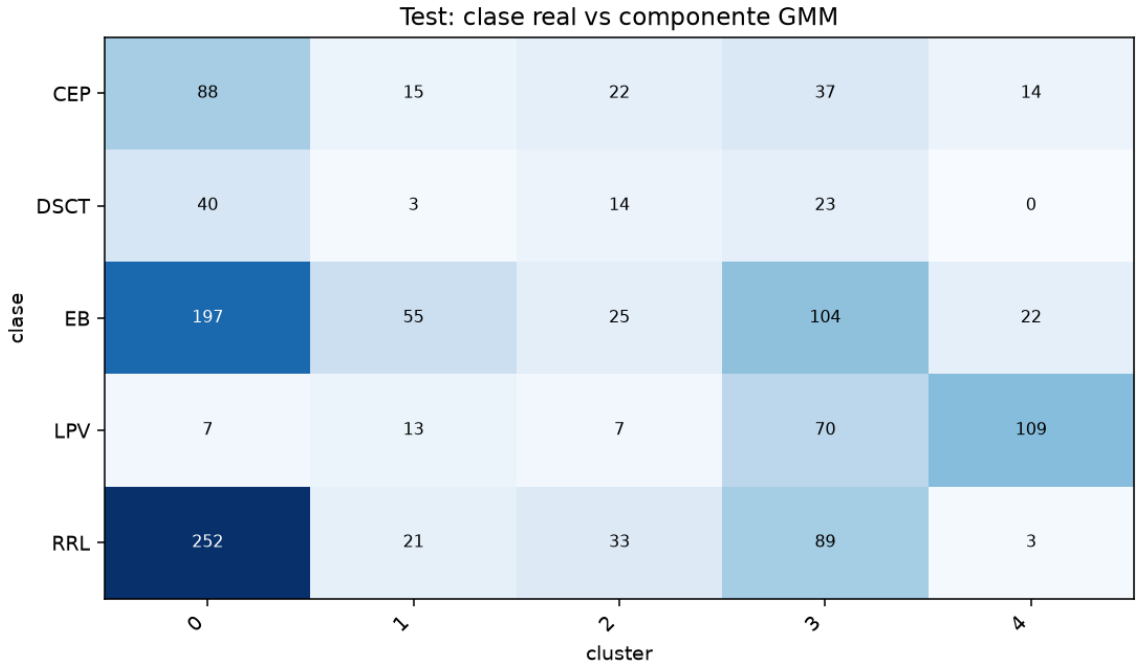
Las cuatro métricas, en una línea cada una

- Silhouette: ¿el punto está más cerca de su grupo que de los otros? De -1 a 1. Más alto, mejor.
- Davies-Bouldin: ¿los grupos están mezclados? Más bajo, mejor.
- Esas dos se calculan dos veces: con los grupos del modelo, y con las clases reales. No miden lo mismo.
- ARI y NMI: ¿los grupos coinciden con la clase? 0 es azar. 1 es perfecto.

Números en el test:

Modelo	Sil. grupos	Sil. clases	DB grupos	ARI	NMI
GMM	0.17	-0.20	2.06	0.10	0.13
MCDSVDD	0.21	0.15	0.83	0.33	0.44

MCDSVDD está en la misma tabla para comparar. Se explica en la sección siguiente. Sil. = Silhouette. DB = Davies-Bouldin. Más alto es mejor en Silhouette, ARI y NMI. Más bajo es mejor en Davies-Bouldin.



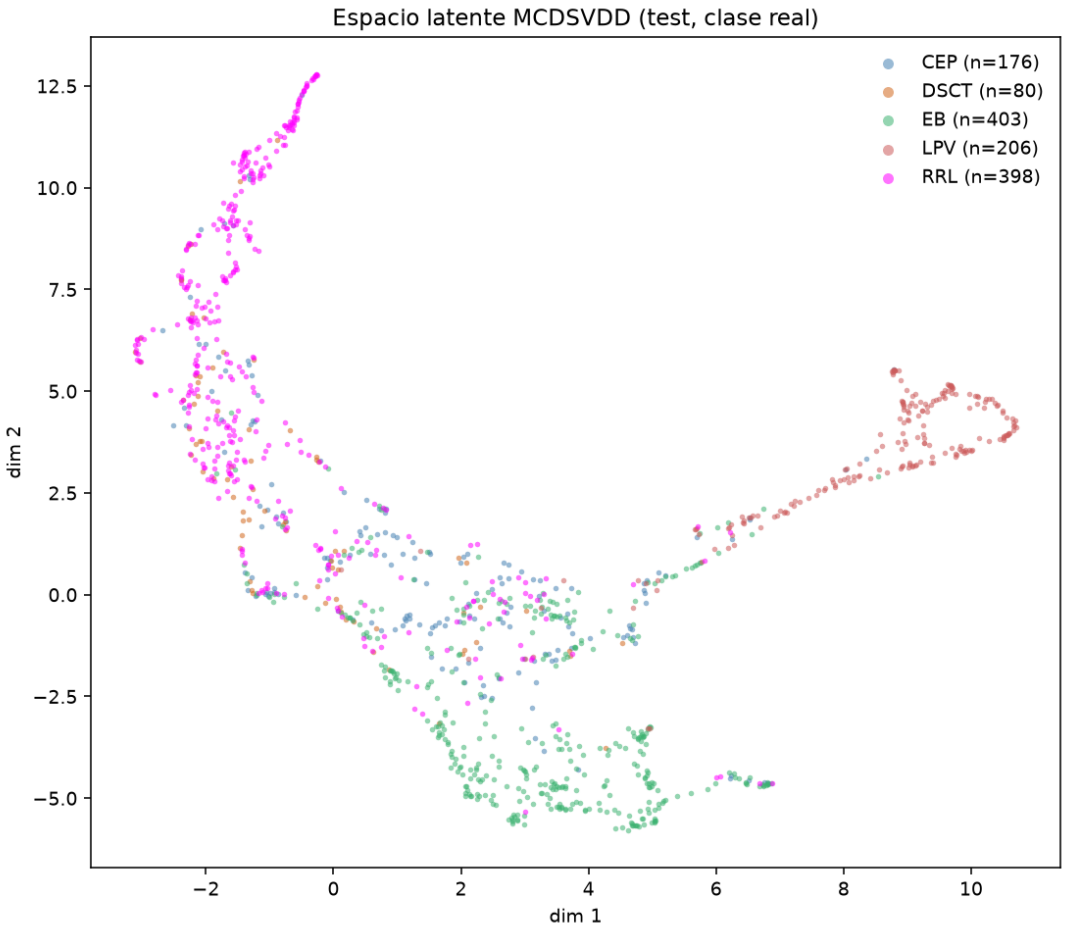
QUÉ DECIR MIRANDO ESTA MATRIZ

Cada fila es la clase real. Cada columna es un grupo que encontró el GMM, sin saber la clase. El primer grupo se lleva a casi todos: 252 RR Lyrae, 197 binarias, 88 Cefeidas y 40 Delta Scuti. O sea, un solo componente mezcla cuatro clases. La excepción es LPV: 109 de 206 caen en el último componente. ARI 0.10. Sin etiquetas, lo único que se recupera con alguna claridad es que las de período largo son distintas.

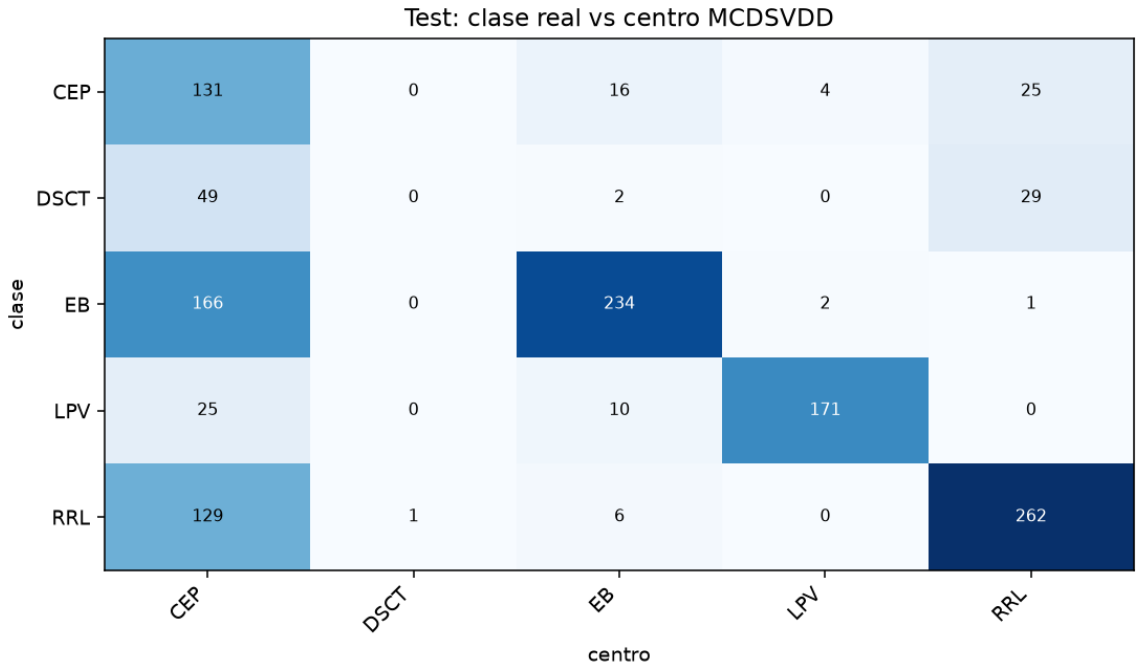
6. MCDSVDD: un centro por clase

El enunciado pide también un método semi-supervisado. Multi-Class Deep SVDD (Pérez-Carrasco y otros, 2023) usa la misma compresión, pero ahora sí conoce la clase durante el entrenamiento. Calcula un centro por clase, como el promedio de sus estrellas en el espacio de 8 números, y mueve la red para que cada estrella quede cerca del centro de la suya. Los centros no se mueven.

En test, la estrella se asigna al centro más cercano. La distancia a ese centro es el puntaje de anomalía: mientras más lejos de todos los centros, más rara. Todavía no usamos ese puntaje para el experimento del paper. Hoy solo medimos si el centro más cercano coincide con la clase.



Acá el color sigue siendo la clase real. A diferencia del autoencoder, LPV (rojo) forma un brazo aparte, RR Lyrae (magenta) se va hacia arriba y las binarias (verde) hacia abajo. Delta Scuti, naranja, no forma su propio grupo: queda repartida.



QUÉ DECIR MIRANDO ESTA MATRIZ

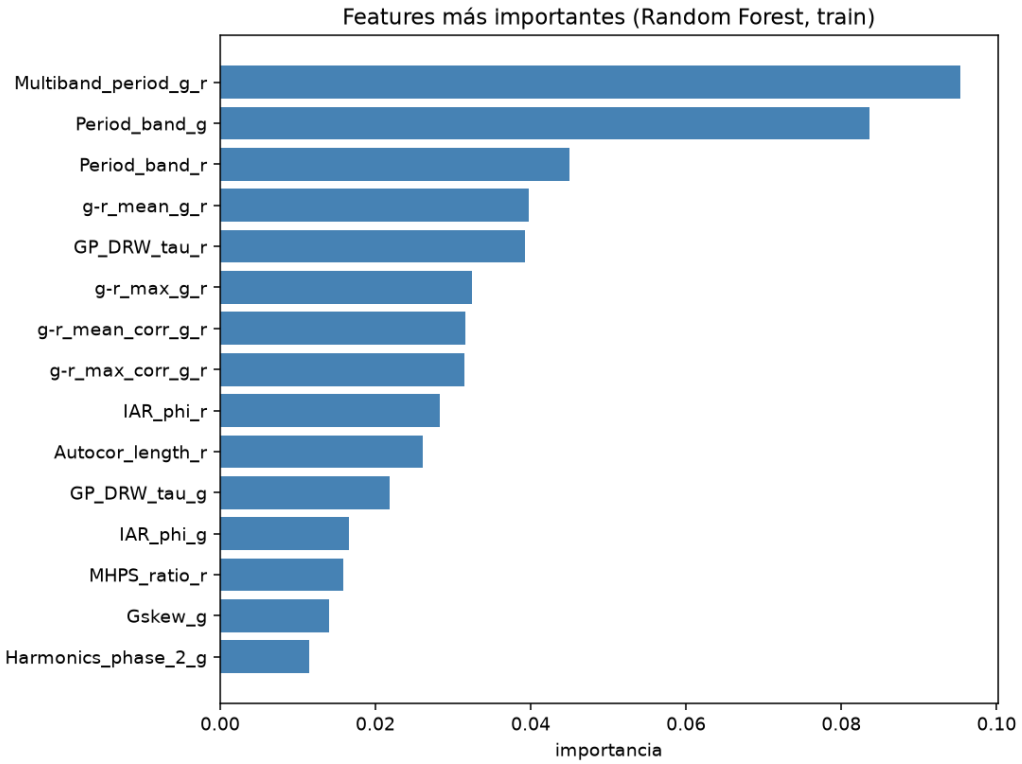
Ahora las columnas sí son clases, porque cada centro es una clase. La diagonal es un acierto. LPV acierta 171 de 206 (83%). Cefeidas, 131 de 176 (74%). RR Lyrae, 262 de 398 (66%). Binarias, 234 de 403 (58%). Delta Scuti acierta 0 de 80. De esas 80, 49 quedan en Cefeidas y 29 en RR Lyrae. ARI 0.33 y NMI 0.44: mejor que el GMM, y lejos de estar resuelto.

POR QUÉ FALLA DELTA SCUTI, Y HAY QUE DECIRLO

Es la clase más chica y el entrenamiento no está balanceado: el error le pesa igual a cada estrella, así que EB y RRL dominan. El modelo casi no reserva un lugar para DSCT. Christian escribió que si MCDSVDD funcionaba mal en esta etapa no importaba. Este es ese resultado, y ya sabemos en qué clase falla.

7. Qué feature importa, y con qué cerrar

Un Random Forest de clasificación, ajustado solo con entrenamiento y con peso extra para las clases chicas, ordena las features. No se usó para borrar columnas del autoencoder. Sirve para decir qué está usando la separación.



Las tres primeras son períodos: el período multibanda, el de la banda g y el de la banda r. Después viene el color g menos r. Era esperable: estas clases viven en escalas de tiempo distintas, de horas a meses. El período no alcanza para separarlas todas, porque los rangos se pisan, pero es la pista más fuerte.

Cierre, en cuatro frases

- Etapa 1, exploración: hecha en el notebook inicial.
- Etapa 2, autoencoder: hecha. El latente de 8 dimensiones no ordena las clases por sí solo.
- Etapa 3, GMM y MCDSVDD: hecha en versión preliminar. El GMM casi no recupera las clases. MCDSVDD mejora y pierde a Delta Scuti.
- Etapa 4, curvas de luz de prototipos y outliers: es lo que sigue. Las curvas ya están. También falta esconder una clase, reentrenar y medir si el modelo la marca como rara (AUROC).

8. Guion para decirlo

Está escrito en frases cortas. No hace falta memorizarlo palabra por palabra. Sí hace falta no saltarse las cajas de color: la partición, que el GMM no ve la clase, y que Delta Scuti queda en cero.

Integrante 1 · del minuto 0 al 7

El proyecto busca grupos y objetos raros entre estrellas cuyo brillo se repite. Los datos son de ALeRCE, sobre el survey ZTF. Cada estrella entra al modelo como una lista de features ya calculadas, no como la curva dibujada. Las curvas las vamos a usar en la etapa siguiente, para mirar prototipos y outliers.

Hay cinco clases: Cefeidas, Delta Scuti, binarias eclipsantes, variables de período largo y RR Lyrae. No están balanceadas. Delta Scuti tiene 532 objetos y las binarias, 2689. En total usamos 8419 estrellas con features.

Separamos 70, 15 y 15, manteniendo la proporción de clases. Imputación, recorte y escala se calculan solo con entrenamiento. Descartamos 20 features que no describen la estrella: no-detecciones previas a la primera alerta, y colores WISE cuando no hay contraparte. A los períodos les aplicamos logaritmo, porque van de horas a cientos de días. Quedan 158 features.

El autoencoder comprime esas 158 features a 8 números y trata de reconstruirlas. Esos 8 son el cuello de botella. La figura es un UMAP del test, solo para mirar: el modelo trabaja en 8 dimensiones. Entrenó 24 épocas y paró con validación. En el dibujo las clases van mezcladas. LPV se aparta un poco. El Silhouette de las clases reales es negativo, -0.20.

Integrante 2 · del minuto 7 al 15

Sobre esos 8 números ajustamos un GMM de 5 componentes, solo con entrenamiento. No usa las etiquetas. En el test, Silhouette y Davies-Bouldin miran si los grupos están separados. ARI y NMI miran si coinciden con la clase. El ARI del GMM es 0.10, casi azar. En la matriz, un componente se lleva a Cefeidas, binarias, RR Lyrae y Delta Scuti. LPV es la excepción: 109 de 206 caen en otro componente.

MCDSVDD es la parte semi-supervisada. Parte del mismo encoder, pone un centro por clase y acerca cada estrella al centro de la suya. En test se asigna al centro más cercano. Mejora: ARI 0.33 y NMI 0.44. LPV acierta alrededor del 83%, las Cefeidas el 74%, RR Lyrae el 66% y las binarias el 58%. Delta Scuti acierta cero de ochenta. Se va a Cefeidas o a RR Lyrae. Es la clase más chica y el entrenamiento no está balanceado. En esta etapa estaba previsto que podía salir mal.

Como extra, un Random Forest solo con entrenamiento rankea las features. Las tres primeras son períodos, y después el color g menos r.

Para cerrar: esto cubre el autoencoder y el clustering con GMM y una primera versión de MCDSVDD. Lo que sigue es mirar las curvas de luz de los objetos típicos y de los raros, y el experimento de esconder una clase para medir si el modelo la detecta como anomalía.

9. Si Christian pregunta

¿El GMM usó las etiquetas?
No. Solo ve la posición en los 8 números. Las etiquetas entran después, para medir ARI y NMI.

¿Por qué el ARI del GMM es tan bajo? ¿Está mal hecho?
El ajuste está bien. El espacio del autoencoder no separa las clases, así que cinco campanas no pueden recuperarlas. El número bajo es un resultado, no un error de código.

¿Hay filtración entre train y test?
No en los modelos. Mediana, recorte, escala y la decisión de qué columnas van a logaritmo salen del entrenamiento. UMAP se ajusta solo para dibujar el test. No se lo pasamos al GMM ni al MCDSVDD.

¿Por qué el autoencoder no termina en tanh, como en el paper?
En el paper las features quedan entre -1 y 1, y tanh calza con eso. Las nuestras están escaladas por mediana y rango intercuartil, y no están acotadas. Por eso la salida es lineal.

¿Qué es el anomaly score?
En el GMM, qué tan poco probable es el punto según las campanas. En MCDSVDD, la distancia al centro más cercano. Lejos significa raro. Todavía no corrimos el experimento de esconder una clase y medir AUROC.

¿Por qué no balancearon el entrenamiento?
Esta versión sigue la pérdida del paper, que promedia sobre las estrellas. EB y RRL pesan más. Balancear es el paso siguiente, junto con el AUROC.

¿Qué es un prototipo y un outlier?
Prototipo: la estrella más cercana al centro de su grupo. Outlier: la que queda en la periferia, con poca probabilidad en el GMM o lejos de todos los centros. Falta mostrar sus curvas plegadas con el período. Esa es la etapa 4.

¿Dónde están las figuras?
En la carpeta results. Las cuatro para mostrar son ae_latente_clases, gmm_clase_cluster, mcdsvdd_latente_clases y mcdsvdd_clase_cluster.

10. Cómo se pronuncia, si se traban

ALeRCE. «alerce», como el árbol. Es el sistema que clasifica las alertas.

ZTF. Zwicky Transient Facility. Se puede decir «el survey ZTF».

Feature. Un número que resume la curva. No es la curva.

Autoencoder. La red que comprime a 8 números y reconstruye.

Cuello de botella o espacio latente. Esos 8 números.

UMAP. «u-map». Un mapa de dos ejes para mirar. No es el modelo.

GMM. Mezcla de gaussianas. Si se traban, digan «mezcla de gaussianas».

MCDSVDD. No hace falta deletrearlo. Digan «el modelo de un centro por clase».

Silhouette. Silueta. Más alto, grupos mejor separados.

Davies-Bouldin. «déivis búldin». Más bajo, mejor.

ARI y NMI. Dos formas de medir si los grupos coinciden con la clase.

Outlier. Objeto raro, en la orilla del grupo.

Prototipo. El objeto más típico del grupo.

ORDEN DE LAS FIGURAS, PARA NO IMPROVISAR
1. results/ae_latente_clases.png
2. results/gmm_clase_cluster.png
3. results/mcdsvdd_latente_clases.png
4. results/mcdsvdd_clase_cluster.png

Si sobra un minuto: results/importancia_rf.png